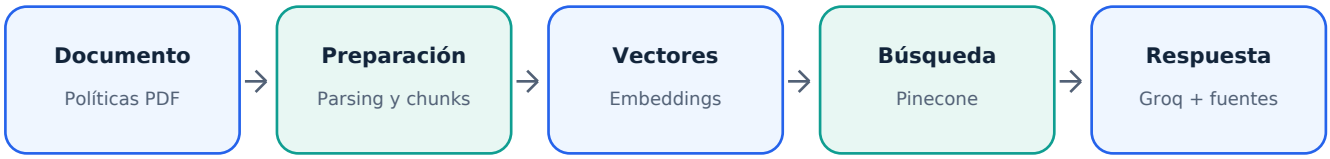
GUÍA VISUAL DE CLASE

Construí un RAG que responda con evidencia

De un PDF de políticas a un asistente comercial conectado con n8n, Pinecone, Cohere y Groq.



El valor del RAG: usar conocimiento específico y recuperarlo cuando hace falta.

¿Qué vas a aprender?

Qué es RAG; cómo se ingesta un documento; qué son chunks, embeddings y una base vectorial; cómo funcionan Top-K y Minimum Score; por qué el modelo puede equivocarse; y cómo integrar el resultado a un agente en n8n.

Caso de estudio: NovaSaaS

Un cliente escribe: «Quiero contratar 25 licencias. ¿Qué descuento me corresponde?». El asistente no debería inventar un descuento. Debe buscar la política vigente, responder solo si encuentra evidencia y, si no la encuentra, pedir validación humana.

Idea clave

RAG no entrena de nuevo al modelo. Recupera información externa relevante y la incorpora al contexto de una consulta.

01 ¿Qué es RAG?

RAG significa Retrieval-Augmented Generation: generación aumentada por recuperación.



Primero recuperamos. Después generamos.

Sin RAG vs. con RAG

Sin RAG	Con RAG
El modelo responde usando el contexto disponible y su conocimiento aprendido.	El modelo recibe fragmentos concretos de los documentos de la organización.
Puede desconocer políticas nuevas o privadas.	Puede consultar políticas actualizadas, si la base se mantiene al día.
Es difícil verificar de dónde salió un dato.	Podemos guardar la fuente y el fragmento que sustentan la respuesta.

¿Qué problema resuelve?

Los modelos de lenguaje no conocen automáticamente el contenido interno de una empresa. Un RAG conecta la pregunta con una fuente de verdad externa: manuales, contratos, catálogos, procedimientos o preguntas frecuentes.

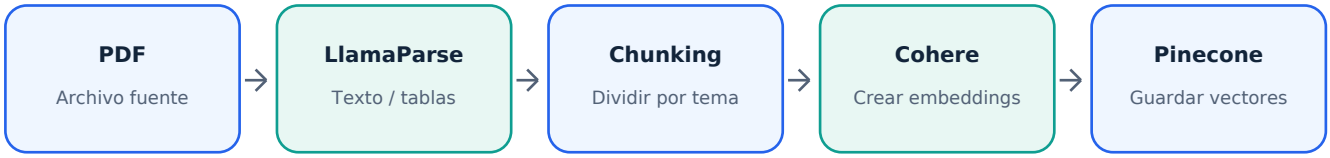
Una analogía para recordar

El LLM es la persona que redacta; el vector store es una biblioteca; los embeddings son el sistema para encontrar libros por significado; y los chunks son los párrafos que leemos antes de responder.

Advertencia: recuperar un texto no demuestra que sea verdadero o vigente. Hay que controlar calidad, versión y permisos.

02 La ingesta: preparar el conocimiento

La ingesta ocurre antes de que un usuario pregunte. Su objetivo es convertir documentos en información recuperable.



Pipeline de indexación: se ejecuta al cargar o actualizar documentos.

Paso A — Parsing

Extraemos el texto del PDF. Si hay tablas, títulos o columnas, el parseo debe conservar su estructura. En clase usamos LlamaParse para inspeccionar el Markdown generado.

Paso B — Chunking

Dividimos el contenido en fragmentos. Un chunk demasiado grande introduce ruido; uno demasiado pequeño puede separar una regla de sus excepciones. El ejemplo de la preentrega de Rómulo usa 26 fragmentos definidos por secciones y conserva las tablas completas.

Paso C — Embeddings

Un embedding es una lista de números que representa el significado aproximado de un texto. La misma tecnología convierte la pregunta en un vector para buscar fragmentos parecidos.

Paso D — Indexación

Pinecone almacena los vectores junto con metadatos como documento, sección, versión y contenido. Esos metadatos ayudan a citar y filtrar resultados.

Regla técnica fundamental

El modelo de embeddings utilizado para insertar y para consultar debe ser compatible: misma dimensión y mismo espacio vectorial. Para documentos en español preferimos un modelo multilingüe; por ejemplo, Cohere embed-multilingual-v3.0 produce vectores de 1024 dimensiones.

03 La consulta: qué pasa cuando llega un correo



Pipeline de consulta: se ejecuta por cada pregunta del usuario.

El recorrido en nuestro proyecto

1. Gmail recibe el correo. 2. El Manager identifica la intención y envía la consulta al Worker Sales. 3. El Worker convierte la consulta en embedding y recupera evidencia de Pinecone. 4. Groq redacta usando esos fragmentos. 5. El Manager recibe el resultado y puede preparar un borrador para revisión.

Dos procesos que no hay que confundir

Ingesta / indexación	Retrieval / consulta
Se ejecuta cuando cambia la documentación.	Se ejecuta cuando llega una pregunta.
Documento → chunks → embeddings → base vectorial.	Pregunta → embedding → búsqueda → evidencia.
Escribe en Pinecone.	Lee desde Pinecone.

¿Qué aporta n8n?

Orquesta servicios especializados sin tener que construir una aplicación completa: Gmail para entrada y salida, nodos de código para normalización y validación, Cohere para embeddings, Pinecone para recuperación y Groq para generación.

¿Y la memoria conversacional?

La memoria guarda el estado o historial del intercambio. No reemplaza a la base documental: una recuerda la conversación; la otra aporta conocimiento verificable de la organización.

04 Top-K, score y reranking

Recuperar información no significa que toda la información recuperada sea útil.

Top-K

Es el máximo de fragmentos devueltos por la búsqueda. Con Top-K = 4, el recuperador entrega hasta cuatro resultados. Un K muy pequeño puede dejar afuera la respuesta; uno muy grande agrega ruido y consume contexto.

Minimum Score

Es un umbral que filtra resultados de baja similitud. En la entrega analizada, Rómulo comparó 0.35 con 0.40 y mostró que 0.40 descartaba varios fragmentos irrelevantes en sus pruebas.



Lo importante del gráfico

La pregunta era sobre el costo de un bot de WhatsApp. El fragmento «Licencias» obtuvo 0.527, más que «Catálogo», que contenía el precio y obtuvo 0.420. Mayor similitud no garantiza respuesta correcta.

Reranking

Es una segunda etapa opcional que reordena los fragmentos según su relevancia para la pregunta completa. Primero recuperamos candidatos; después los reordenamos. Suele mejorar precisión, pero añade latencia y puede tener costo.

Cuidado: los scores no son probabilidades de verdad y no existe un umbral universal. Se calibran con consultas representativas de cada base.

05 Evitar respuestas inventadas

Un RAG puede alucinar aunque la búsqueda funcione. Por eso necesitamos instrucciones, evidencia y controles.

Tres reglas para el agente

1. Fuente de verdad: usar únicamente los fragmentos recuperados para afirmar políticas, precios y plazos.

2. Regla de contingencia: si la evidencia no contiene el dato, responder «No encuentro esa información en la documentación disponible» y escalar si corresponde.

3. Trazabilidad: incluir documento y sección de donde sale cada afirmación relevante.

Ejemplo de prompt para el Worker Sales

Instrucción del sistema
Sos un asistente comercial de NovaSaaS. Respondé las consultas utilizando exclusivamente la evidencia documental entregada. No inventes descuentos, condiciones, plazos ni precios. Si la evidencia es insuficiente, indicá que necesitás confirmación. Citá la fuente y sección de cada política utilizada. Devolvé una respuesta clara y breve.

¿Qué pasa si se recupera un fragmento irrelevante?

El filtro de score es la primera barrera; el prompt es la segunda. Ninguna garantiza precisión perfecta. En la entrega de Rómulo, una pregunta sin respuesta documental recuperó un fragmento relacionado con «clientes», pero el agente respondió que no sabía.

Human-in-the-loop

Para decisiones sensibles —por ejemplo, autorizar un descuento o prometer una devolución— el agente puede generar un borrador y pedir aprobación humana antes de enviarlo.

06 Qué probamos y cómo evaluamos

Una respuesta convincente no es suficiente: debemos verificar que sea correcta y esté respaldada.

Prueba	Qué esperamos
Pregunta con respuesta explícita	Recupera la sección correcta y cita la política.
Pregunta con sinónimos	Encuentra la respuesta aunque use otras palabras.
Pregunta sin respuesta	Reconoce el límite; no inventa datos.
Pregunta que combina políticas	Integra varias secciones sin mezclar condiciones.
Documento desactualizado	Usa solo la versión vigente de la política.

Evidencia de la preentrega analizada

Rómulo reportó 5/5 respuestas correctas en cinco correos de prueba, con citas de fuentes y un caso donde aplicó «No sé». También detectó sobre-citación y una promesa no respaldada. Es una evaluación inicial, no una precisión general del 100 %.

Métricas útiles para profundizar

Recall@K: ¿apareció el fragmento que necesitábamos entre los K recuperados? Precision@K: ¿cuántos de los recuperados eran realmente relevantes? Faithfulness: ¿la respuesta está respaldada por el contexto? Latencia: ¿cuánto tarda en responder?

Actividad de clase

Probá tres preguntas sobre NovaSaaS: (a) una política que exista en el PDF, (b) la misma pregunta con sinónimos y (c) una pregunta que el PDF no responda. Compará los chunks recuperados, sus scores y el texto final. Registrá qué cambió al ajustar Top-K o el umbral.

07 Errores reales que vimos en n8n y Pinecone

Síntoma	Causa y aprendizaje
Sub-workflow isn't set up to accept inputs	El trigger del Worker no exponía el contrato de entrada. Definir original_input, intent, confidence y risk.
Los campos del ejemplo aparecen null	El JSON Example define el esquema; no necesariamente inyecta valores de ejecución. Probar desde Manager o con datos fijados.
HTTP 404 al buscar índice	Revisar nombre exacto del índice y proyecto asociado a la API Key.
This index has a document schema	El nodo vectorial clásico no usa la Documents API. Crear un índice vectorial BYOV compatible o implementar la API documental por HTTP.
No aparecen fragmentos relevantes	Comprobar que el índice contenga vectores, que la dimensión coincida y que se use el mismo modelo de embeddings.

Diseño recomendado para la demostración



Arquitectura propuesta para la clase; requiere ingesta completa antes de consultar.

Importante sobre Pinecone

El índice de documentos que vimos en la consola contenía tres registros del PDF, pero no era compatible con el nodo Pinecone Vector Store clásico. Crear otro índice no mueve automáticamente esos documentos: hay que volver a cargar los fragmentos y generar sus embeddings.

08 Gobernanza y cierre: un RAG útil en producción

La base de conocimiento también se mantiene

El PDF no es eterno. Si cambian los descuentos, condiciones de pago o procedimientos, debemos actualizar el documento, volver a indexarlo y evitar que convivan políticas contradictorias.

Checklist de un RAG responsable

• Documento con dueño, versión y fecha de revisión.

• Parsing validado: tablas, títulos y excepciones completos.

• Chunks con metadatos y fuente identificable.

• Embeddings consistentes entre ingesta y búsqueda.

• Top-K y umbral calibrados con preguntas reales.

• Respuesta respaldada por evidencia y regla de «No sé».

• Revisión humana para compromisos comerciales sensibles.

• Pruebas repetidas cada vez que cambia la base.

El valor de construir RAG

No consiste solo en «hacer que un chatbot lea un PDF». Consiste en convertir conocimiento documental en un sistema consultable, trazable, actualizable y evaluable. La automatización gana valor cuando puede explicar de dónde salió cada respuesta y reconocer cuándo debe pedir ayuda.

Para debatir con el curso

Si un cliente pregunta por un descuento y el vector store devuelve una política parecida, pero no la correspondiente a su caso, ¿qué preferimos: una respuesta inmediata o una derivación a una persona? ¿Qué riesgo tiene cada decisión?

Material utilizado

Esta guía se apoya en la clase de NovaSaaS (n8n, LlamaParse, Pinecone, Cohere y Groq) y en la preentrega «Agente con Conocimiento Organizacional» de Rómulo Coronado, especialmente sus ejemplos de chunking, Top-K, Minimum Score, pruebas y gobernanza. Los ejemplos de NovaSaaS son didácticos; no implican que la integración esté desplegada y validada.

Fin de la guía · Del documento a la respuesta con evidencia

ANEXO VISUAL · Apuntes de clase ampliados

Cómo mejorar la recuperación en un RAG

Estos conceptos amplían el recorrido de la consulta: filtros por metadatos, búsqueda vectorial, reranking, contexto y métricas de calidad. El objetivo es entender por qué recuperar «algo parecido» no alcanza.



1. Recuperación: no es lo mismo encontrar que responder

Cuando una persona pregunta, el sistema identifica qué necesita, convierte la consulta en una representación vectorial y busca fragmentos relacionados. Luego prepara un contexto para el LLM. El retrieval selecciona evidencia; el LLM la interpreta y redacta. Son responsabilidades distintas.

2. Filtros por metadatos: acotar antes de buscar

Los metadatos describen los documentos sin ser su contenido principal: categoría, producto, fecha, versión, idioma, área, tipo de política o permisos. Podemos filtrar antes de la búsqueda semántica para evitar recuperar información de otra categoría o de una versión vencida.

Pregunta	Filtro posible	Por qué ayuda
«¿Qué descuento aplica a 25 licencias?»	producto = licencias; estado = vigente	Evita mezclar precios de soporte o promociones caducadas.
«¿Cómo restablezco mi contraseña?»	categoría = acceso	Reduce resultados comerciales que mencionen usuarios.
«¿Cuál es la política actual?»	versión = actual	Evita usar documentos reemplazados.

Importante: un filtro mal configurado también puede excluir la respuesta correcta. Primero hay que tener metadatos confiables.

3. Búsqueda léxica, semántica e híbrida

Léxica: encuentra coincidencias de términos (útil para códigos y nombres exactos). Semántica: busca cercanía de significado mediante embeddings (útil para sinónimos). Híbrida: combina ambas señales, cuando la infraestructura lo permite.

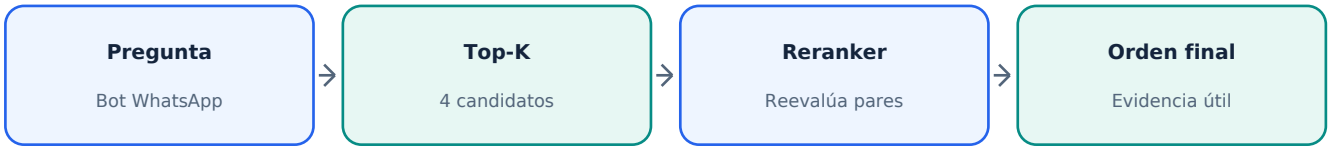
ANEXO VISUAL · Calidad del retrieval

Top-K, reranking y métricas

4. Top-K: recuperar candidatos

Con Top-K = 4 pedimos hasta cuatro fragmentos candidatos. Es una decisión de cobertura y costo: un K bajo puede omitir la evidencia; un K alto puede incorporar ruido. El mejor valor se determina con pruebas.

5. Reranking: elegir el orden más útil



El recuperador vectorial compara representaciones numéricas. Un reranker examina la pregunta y cada fragmento candidato con más detalle y los reordena. Por ejemplo, «Licencias» puede parecer más parecido a «bot de WhatsApp», pero «Catálogo» puede contener el precio exacto que se necesita.

El reranking no crea datos ni garantiza que exista una respuesta; solo prioriza candidatos. Es una etapa opcional que consume recursos y puede aumentar la latencia.

6. Precision y Recall: dos formas de medir recuperación

Métrica	Pregunta que responde	Ejemplo
Precision@K	De los K fragmentos devueltos, ¿cuántos eran relevantes?	Si devuelve 4 y 2 sirven, Precision@4 = 2/4 = 50 %.
Recall@K	De todos los fragmentos relevantes conocidos, ¿cuántos recuperó?	Si hay 3 relevantes y recuperó 2, Recall@4 = 2/3 ≈ 67 %.

No alcanza con medir «el bot contestó». También interesa si recuperó la evidencia correcta, si la respuesta está sustentada y si tardó un tiempo razonable.

7. ¿Qué es un modelo BGE?

BGE es una familia de modelos de embeddings y reranking. Es una alternativa tecnológica, no un paso obligatorio del RAG. En nuestra implementación de clase usamos Cohere para embeddings y podemos activar un reranker compatible. No debemos confundir el nombre de un modelo con el proceso de recuperación.

8. ¿Dónde entra el contexto?

Después de recuperar y, si corresponde, filtrar y reordenar, se entregan los fragmentos al modelo junto con instrucciones claras. Ese conjunto forma el contexto de respuesta. El LLM no debería completar con suposiciones una política que no está allí.

ANEXO VISUAL · Aplicación a NovaSaaS

Del apunte al workflow de n8n



9. Qué hace cada componente

Componente	Responsabilidad
Manager multiagente	Recibe el correo, identifica intención, deriva al Worker y conserva el contrato de entrada/salida.
Embeddings Cohere	Representa la pregunta como vector en el mismo espacio que los documentos indexados.
Pinecone	Busca los fragmentos candidatos dentro del índice vectorial.
Filtro por score	Descarta candidatos que no superan el umbral definido para el experimento.
Reranker (opcional)	Reordena candidatos para priorizar los que responden mejor a la pregunta.
Groq	Redacta una respuesta usando el contexto recuperado y las reglas del prompt.
Revisión humana	Valida descuentos, compromisos o decisiones sensibles antes del envío.

10. Experimento guiado para el curso

Pregunta A: «¿Qué descuento me corresponde por 25 licencias?» Pregunta B: «¿Hay alguna bonificación si compro varias cuentas?» Pregunta C: «¿Tienen estacionamiento gratuito?»

Para cada pregunta, registren: chunks recuperados, score, fuente, si existe evidencia suficiente y respuesta final. Después comparen Top-K = 2 frente a Top-K = 4, y prueben el filtro de score. Si el índice no tiene información sobre estacionamiento, el resultado esperado es reconocer que no hay evidencia.

11. Preguntas de discusión

¿Un score alto equivale a una respuesta verdadera? ¿Qué pasa si el filtro elimina el chunk correcto? ¿Cuándo conviene un reranker? ¿Cómo evitamos usar políticas viejas? ¿Por qué una respuesta sin fuente no es suficiente para una decisión comercial?

Nota sobre los apuntes originales

Este anexo reorganiza y amplía las ideas manuscritas sobre retrieval, filtros, reranking, contexto, precisión, recall y flujo de pregunta-respuesta. Las explicaciones y ejemplos de NovaSaaS se agregaron con finalidad didáctica.